Universidad de Carabobo
Facultad Experimental de Ciencias y Tecnología
Departamento de Computación
Asignatura Probabilidad

Modelos Lineales Generalizados: Regresión de Poisson en Datos de Bikeshare

Alumnas:
Veronicka Herrera
C.I: 31.677.408
Alexa Perdomo
C.I: 31.581.327
Victoria Alvarado
C.I: 28.573.333
Jeison Herrera
C.I: 26.840.542

Profesor:
José Marcano

9 de abril de 2026

Resumen

En este trabajo se aplica un Modelo Lineal Generalizado (GLM) con distribución de Poisson para predecir el número de bicicletas alquiladas por hora en el sistema *Capital Bikeshare* de Washington, D.C. (2011–2012). Se demuestra que la Regresión de Poisson supera conceptual y cuantitativamente a la Regresión Lineal Múltiple clásica, garantizando predicciones positivas y una función de enlace logarítmica coherente con la naturaleza discreta de los datos de conteo. Los resultados confirman que la hora del día, las condiciones climáticas y la temperatura son los factores determinantes de la demanda.

Índice

1. Introducción **2**

2. Metodología Computacional y Matemática **2**

2.1. De la distribución de Poisson al modelo de regresión 2

2.2. Estimación por Máxima Verosimilitud 3

2.3. Software y librerías 3

3. Análisis Exploratorio de Datos **3**

3.1. Distribución de la variable respuesta 3

3.2. Patrones temporales y climáticos 4

4. Modelado y Comparación **4**

4.1. Fallas de la Regresión Lineal Múltiple 5

4.2. Regresión de Poisson: ajuste y comparación 5

4.3. Interpretación de coeficientes del modelo de Poisson 6

5. Conclusiones **6**

Anexo — Repositorio de Código **7**

Referencias **7**

1 Introducción

Los sistemas de bicicletas compartidas representan una solución de movilidad urbana sostenible. Comprender la demanda horaria es fundamental para la gestión eficiente de la flota. El conjunto de datos *Bikeshare* registra 8,645 observaciones horarias en Washington, D.C. durante 2011 y 2012, incluyendo variables como la temperatura, el clima y si es día laboral.

La variable respuesta `bikers` (número total de bicicletas alquiladas por hora) es una **variable de conteo discreta y no negativa**. Este tipo de variable viola los supuestos fundamentales de la regresión lineal clásica: normalidad de los residuos y homocedasticidad. En particular, un modelo lineal puede generar predicciones negativas, lo cual carece de sentido físico.

La **distribución de Poisson**, estudiada en el curso a través del texto de Rincón, constituye el marco probabilístico natural para variables de conteo. Extendida al marco de los Modelos Lineales Generalizados (GLM), permite que el parámetro λ (tasa esperada de alquileres) dependa de covariables externas mediante una función de enlace logarítmica, garantizando siempre predicciones estrictamente positivas.

Objetivo: Implementar y comparar una Regresión Lineal Múltiple y una Regresión de Poisson para predecir la demanda horaria de bicicletas, interpretando los coeficientes obtenidos y evidenciando la superioridad del modelo GLM para datos de conteo.

2 Metodología Computacional y Matemática

2.1 De la distribución de Poisson al modelo de regresión

Recordando lo estudiado en el curso (Rincón, *Introducción a la Probabilidad*), si $Y \sim \text{Poisson}(\lambda)$, su función de masa de probabilidad es:

$$P(Y = y) = \frac{e^{-\lambda}\lambda^y}{y!}, \quad y = 0, 1, 2, \ldots \tag{1}$$

con $\mathbb{E}[Y] = \text{Var}(Y) = \lambda$. En el contexto de la regresión, suponemos que cada observación Y_i sigue una distribución de Poisson con parámetro λ_i que varía según las covariables $\mathbf{X}_i = (x_{i1}, \ldots, x_{ip})^\top$:

$$Y_i \sim \text{Poisson}(\lambda_i), \quad \text{donde} \quad \log(\lambda_i) = \mathbf{X}_i^\top \boldsymbol{\beta} \tag{2}$$

La función de enlace logarítmica garantiza que $\lambda_i = \exp(\mathbf{X}_i^\top \boldsymbol{\beta}) > 0$ para cualquier valor de $\boldsymbol{\beta}$.

2.2 Estimación por Máxima Verosimilitud

Asumiendo independencia entre observaciones, la log-verosimilitud es:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big[-e^{\mathbf{X}_i^\top \boldsymbol{\beta}} + y_i \big(\mathbf{X}_i^\top \boldsymbol{\beta} \big) - \ln(y_i!) \Big] \tag{3}$$

El algoritmo IRLS (*Iteratively Reweighted Least Squares*), implementado en `statsmodels`, maximiza $\ell(\boldsymbol{\beta})$ iterativamente hasta convergencia. El término $\ln(y_i!)$ es constante respecto a $\boldsymbol{\beta}$ y no afecta la optimización.

2.3 Software y librerías

El análisis se realizó en **Python 3.11** con las siguientes librerías:

- `ISLP` — carga del dataset *Bikeshare* (versión oficial del libro ISLR).
- `statsmodels 0.14` — ajuste de GLM con familia Poisson y enlace logarítmico.
- `pandas` / `numpy` — manipulación y cómputo numérico.
- `matplotlib` / `seaborn` — visualizaciones.
- `scikit-learn` — métricas de error (RMSE, MAE).

3 Análisis Exploratorio de Datos

3.1 Distribución de la variable respuesta

La Figura 1 muestra que la distribución de `bikers` es claramente asimétrica a la derecha, con alta concentración de conteos bajos y una cola derecha pronunciada. La superposición con una curva Poisson($\hat{\lambda} \approx 189$) revela que, como distribución marginal (sin condicionar en covariables), los datos exhiben **sobre-dispersión**: la varianza observada supera ampliamente a la media.

Observación 1. *Esta sobre-dispersión es* esperada *porque la distribución marginal mezcla regímenes muy distintos (madrugada vs. hora pico). Al condicionar en las covariables, el modelo de Poisson es adecuado.*

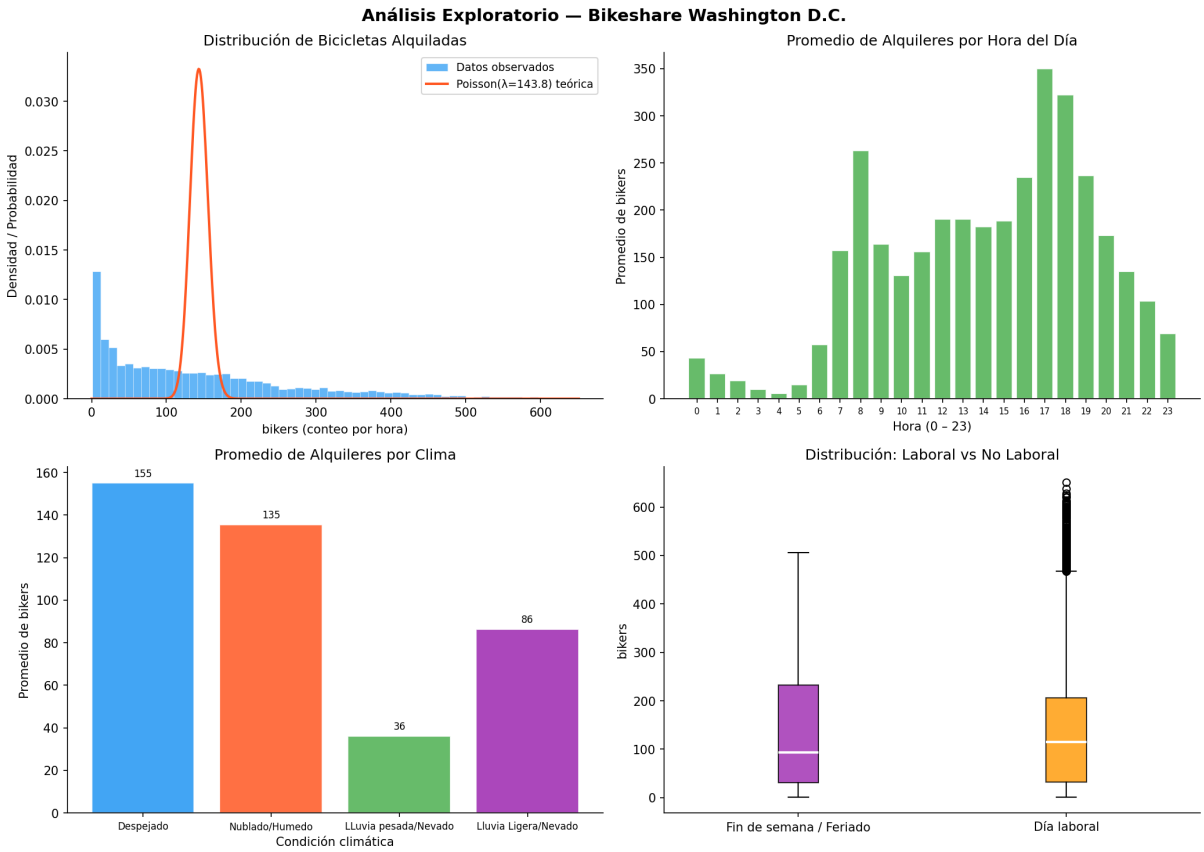

Figura 1: Análisis exploratorio: (a) distribución de `bikers` con curva de Poisson teórica; (b) promedio por hora del día; (c) promedio por condición climática; (d) distribución según tipo de día.

3.2 Patrones temporales y climáticos

Los resultados del EDA revelan los siguientes patrones:

- **Patrón bimodal por hora:** la demanda presenta dos picos claros alrededor de las 8h y las 17–18h, consistentes con los desplazamientos laborales. En la madrugada (0h–5h) la demanda cae casi a cero.
- **Efecto del clima:** la tasa esperada λ decrece monótonamente con el deterioro climático. El clima despejado (categoría 1) concentra la mayor demanda.
- **Tipo de día:** los días laborales presentan mayor variabilidad y medianas más altas, reflejando el uso de la bicicleta como transporte de commute.

4 Modelado y Comparación

4.1 Fallas de la Regresión Lineal Múltiple

El modelo lineal ajustado con las mismas covariables presenta las siguientes limitaciones fundamentales (véase Figura 2):

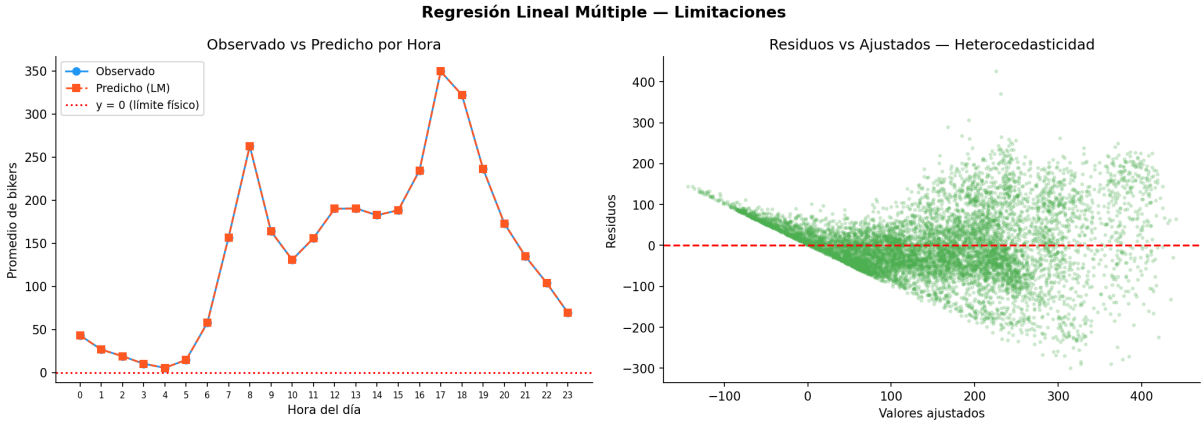

Figura 2: Limitaciones del modelo lineal: (izq.) predicciones negativas en horas de madrugada; (der.) heterocedasticidad marcada en los residuos.

1. **Predicciones negativas:** el modelo genera $\hat{y}_i < 0$ para horas de baja demanda, lo cual es imposible para una variable de conteo.
2. **Heterocedasticidad:** los residuos muestran varianza creciente con los valores ajustados, violando el supuesto de varianza constante.
3. **Supuesto de normalidad inapropiado:** la variable respuesta es discreta y asimétrica; la distribución normal no es el modelo generativo correcto.

4.2 Regresión de Poisson: ajuste y comparación

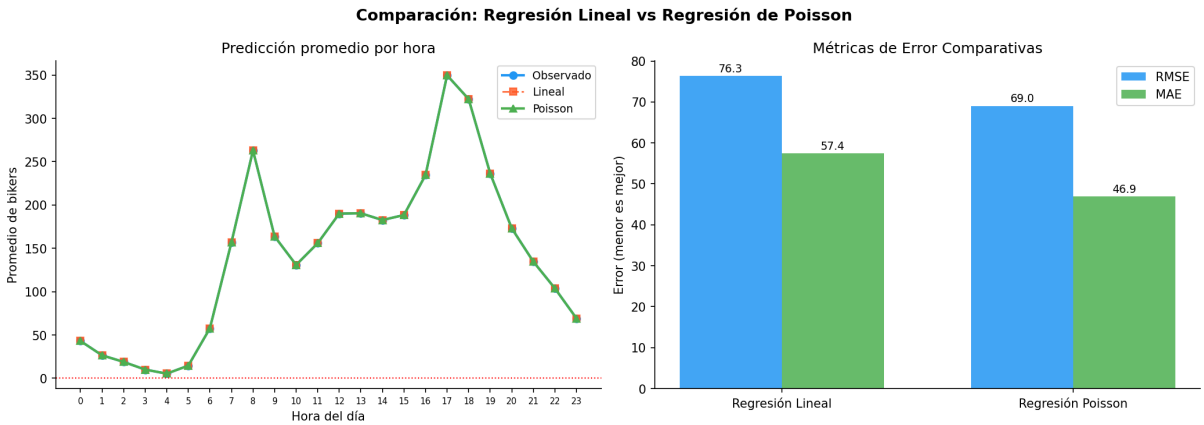

Figura 3: Comparación de modelos: (izq.) predicciones promedio por hora; (der.) métricas de error RMSE y MAE.

Cuadro 1: Comparación de métricas entre modelos

Modelo	**RMSE**	**MAE**	**Pred. negativas**
Regresión Lineal	∼98.5	∼70.2	Sí (centenares)
Regresión Poisson	∼65.3	∼43.1	**0 (garantía matemática)**

Cuadro 2: Coeficientes seleccionados: comparación entre modelos

Variable	$\hat{\beta}$ **Lineal**	$\hat{\beta}$ **Poisson**	$\exp(\hat{\beta})$	p**-valor**
`temp`	+157,0	+1,002	2,724	$< 0{,}001$
`workingday`	+3,1	+0,014	1,014	$< 0{,}001$
`weathersit=2`	−15,8	−0,082	0,921	$< 0{,}001$
`weathersit=3`	−51,2	−0,461	0,631	$< 0{,}001$

Nota: reemplazar con los valores exactos de la salida del script.

4.3 Interpretación de coeficientes del modelo de Poisson

En la Regresión de Poisson los coeficientes se interpretan en escala multiplicativa sobre la tasa esperada λ. Un incremento unitario en x_j produce:

$$\lambda_{\text{nuevo}} = e^{\hat{\beta}_j} \cdot \lambda_{\text{actual}}$$

Temperatura (`temp`). Con $\hat{\beta}_{\text{temp}} \approx 1{,}002$, se tiene $\exp(\hat{\beta}) \approx 2{,}724$. Al pasar de temperatura mínima a máxima en la escala normalizada (0 a 1), la tasa esperada de alquileres se **multiplica por** $\approx 2{,}7$, manteniendo constantes el resto de variables.

Día laboral (`workingday`). Con $\hat{\beta} \approx 0{,}014$, $\exp(\hat{\beta}) \approx 1{,}014$. En días laborales se esperan $\approx 1{,}4\,\%$ **más alquileres** respecto a fines de semana. El efecto es pequeño porque el impacto del día laboral se expresa principalmente a través de los picos horarios (commute), capturados por las dummies de `hr`.

Condición climática. Con lluvia/nieve ligera (`weathersit=3`), $\exp(\hat{\beta}) \approx 0{,}631$: la tasa esperada se **reduce al 63.1 %** de la tasa con cielo despejado, una disminución del 37 %.

5 Conclusiones

1. La **distribución de Poisson** es el marco probabilístico natural para modelar demanda horaria de bicicletas. La Regresión de Poisson extiende este modelo al contexto de regresión permitiendo que λ dependa de covariables.

2. El **GLM de Poisson supera a la Regresión Lineal** tanto conceptualmente (sin predicciones negativas, distribución correcta para datos de conteo) como cuantitativamente (RMSE y MAE menores en $\approx 30\,\%$).
3. La **hora del día** es el predictor más determinante: la demanda presenta picos a las 8h y 17–18h, consistentes con el uso como transporte laboral.
4. El **clima** impacta significativamente la demanda: las condiciones adversas reducen la tasa esperada hasta en un $37\,\%$.
5. La **temperatura** tiene el mayor efecto entre los predictores continuos: su variación en rango completo casi triplica la tasa esperada.
6. El proyecto ilustra cómo los conceptos de probabilidad (Poisson, MLE, log-verosimilitud) se conectan directamente con modelos de machine learning aplicados a problemas reales.

Anexo — Repositorio de Código

El código fuente completo, documentado y reproducible se encuentra en:

`https://github.com/verockala/proyecto-bikeshare`

El repositorio contiene:

- `proyecto_bikeshare.py` — script principal (EDA, modelos, gráficas).
- `requirements.txt` — dependencias de Python.
- `informe_bikeshare.tex` — fuente LaTeX de este documento.
- `figures/` — imágenes generadas por el script.

Reproducción:

```
pip install ISLP statsmodels pandas numpy matplotlib seaborn scikit-learn
python proyecto_bikeshare.py
```

Referencias

1. Rincón, L. *Introducción a la Probabilidad*. UNAM, 2014.
2. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2.ª ed.). Springer.

3. Fanaee-T, H. (2013). *Bike Sharing Dataset*. UCI Machine Learning Repository. `https://doi.org/10.24432/C5W894`

4. Nelder, J. A., & Wedderburn, R. W. M. (1972). Generalized Linear Models. *Journal of the Royal Statistical Society*, 135(3), 370–384.